

CardioCare

중단간 머신러닝 시스템 구축 — 심장병 발병 가능성 예측

기계학습 기말 프로젝트 | 컴퓨터공학과 4학년

1. 문제 정의와 사용 목적

심장 질환은 전 세계 주요 사망 원인 중 하나이며, 조기 발견이 예후에 결정적인 영향을 미친다. CardioCare는 임상 검사 수치를 입력받아 심장병 발병 가능성을 예측하는 머신러닝 기반 의사결정 보조 시스템이다. 핵심 설계 원칙은 "알리되, 결정하지 않는다(inform, not decide)"이다. 즉, 시스템은 위험 신호를 심장 전문의에게 전달하는 역할을 하며, 최종 진단 및 치료 결정은 반드시 임상 전문가에 의해 이루어져야 한다.

이 시스템에서 false negative(실제 심장병 환자를 정상으로 분류하는 오류)는 false positive보다 훨씬 심각한 결과를 초래한다. false negative가 발생하면 실제로 치료가 필요한 환자의 추가 검진과 follow-up이 지연되고, 최악의 경우 생명에 직결되는 골든 타임을 놓칠 수 있다. 따라서 모델 선택 기준에서 recall을 우선 지표로 삼았다.

2. 데이터와 EDA 핵심 결과

2.1 데이터셋 개요

사용한 데이터는 UCI Heart Disease 통합 데이터셋으로, Cleveland, Hungarian, Switzerland, VA 4개 기관의 데이터를 합산한 버전이다. 데이터는 src/preprocessing.py의 download_uci_sources() 함수로 UCI 공식 저장소에서 결정론적으로 다운로드할 수 있으며, 전처리 결과는 data/heart_disease.csv에 저장된다. 918행, 13개 입력 특성, 1개 이진 타깃(0=정상, 1=심장병)으로 구성되며, 타깃의 원본 다중 클래스 레이블(0~4)은 0=정상, 1~4=심장병으로 이진화하였다.

특성	타입	설명
age	연속형	나이 (세)
sex	범주형	성별 (0=여, 1=남)
cp	범주형	흉통 유형 (1~4)
trestbps	연속형	안정 시 혈압 (mmHg)
chol	연속형	혈청 콜레스테롤 (mg/dl)
fbs	범주형	공복 혈당 > 120 여부
restecg	범주형	안정 심전도 결과
thalach	연속형	최대 심박수
exang	범주형	운동 유발 협심증 여부
oldpeak	연속형	운동 유발 ST 하강
slope	범주형	ST 분절 기울기
ca	범주형	주요 혈관 수 (형광 조영)
thal	범주형	탈리움 스트레스 검사 결과

표 1. UCI Heart Disease 데이터셋 입력 특성 목록

2.2 EDA 결과 요약

타깃 분포는 정상 410건(44.6%), 심장병 508건(55.4%)으로 비교적 균형에 가깝다. 완전한 균형은 아니므로 단순 accuracy는 다수 클래스 방향으로 편향될 수 있어 balanced accuracy를 주 평가 지표로 채택하였다. 이는 각 클래스의 recall을 동등하게 평균하므로 클래스 비율에 무관하게 양쪽 오분류를 공정하게 반영한다.

연속형 특성 중 chol(콜레스테롤)은 0mg/dl인 임상적 이상값이 다수 존재하며 IQR 기준 상한 초과 케이스도 관찰되었다. oldpeak 역시 임상 허용 범위를 벗어난 음수 값과 극단적 양수 값이 포함되어 IQR 클리핑 후 중앙값 대체를 적용하였다. ca와 thal은 '?'로 표기된 결측값이 있어 최빈값 대체를 적용하였다. 중복 행은 clean_heart_disease_frame()에서 drop_duplicates()로 제거하였고, 임상 범위 이탈값은 결측 처리 후 파이프라인 내에서 대체하도록 설계하였다.

CardioCare EDA 요약




그림 1. 타깃 분포, 연속형 특성 분포, 결측 및 이상치 현황

3. 전처리 결정

데이터 누수(leakage)를 방지하기 위해 train/test split을 먼저 수행한 뒤, 모든 학습 가능한 변환(imputer, scaler, feature selector)을 sklearn Pipeline 내부에서 fit하였다. split 비율은 test_size=0.2, stratify=y, random_state=42를 사용하였다 (src/train.py).

대상 특성	처리 단계	근거
연속형 (age, trestbps, chol, thalach, oldpeak)	IQR clipping → 중앙값 대체 → StandardScaler	chol의 0값 등 임상적 이상값을 클리핑하고, SVC·로지스틱 회귀에 맞게 표준화
범주형/코드형 (sex, cp, fbs, restecg, exang, slope, ca, thal)	최빈값 대체 → 원-핫 인코딩	ca, thal의 '?' 결측값 처리; slope 포함 순서 없는 범주형은 원-핫 인코딩으로 변환
중복·이상값	drop_duplicates() → 임상 범위 이탈값 결측 처리	정확한 레이블 없는 중복 행 제거; 임상 범위 이탈값은 NaN 처리 후 파이프라인 내 대체
특성 선택	SelectFromModel (랜덤 포레스트, threshold=median)	split 이후 train fold에서만 fit; 중요도 기반으로 불필요 특성 제거

표 2. 특성 유형별 전처리 단계 및 선택 근거

최종 선택된 특성은 14개이다: age, trestbps, chol, thalach, oldpeak(연속형 5개)와 sex_0.0, sex_1.0, cp_2.0, cp_3.0, cp_4.0, exang_0.0, exang_1.0, thal_3.0, thal_7.0 (범주형 OHE 9개). 전체 파이프라인은 새 데이터에 그대로 재적용 가능한 구조로 구성되었다 (artifacts/baseline_svc_selected_features.txt).

4. 특성 공학과 모델 실험

서로 다른 계열의 4가지 모델을 비교하였다: Logistic Regression, SVC(기본), Random Forest, 그리고 GridSearchCV를 통해 튜닝한 SVC(튜닝). 스케일링은 모든 모델에 StandardScaler를 적용하였다. SVC는 커널

함수가 특성 간 거리에 민감하므로 표준화가 필수이고, Logistic Regression도 정규화 항(C)이 스케일에 영향을 받아 표준화가 권장된다. Random Forest는 분기 기준이 스케일 불변이나 동일 Pipeline 구조를 유지하기 위해 함께 적용하였다.

모든 실험은 MLflow로 추적하였으며 각 run에 파라미터, 5-fold CV 지표, test 지표, confusion matrix(CSV/PNG), 선택된 특성 목록, fitted model artifact, model_family 태그를 기록하였다. MLflow에 confusion matrix와 선택 특성 목록을 artifact로 남겨두어, 최종 모델 선택 근거를 나중에 다시 확인할 수 있도록 하였다. SVC 튜닝 시 GridSearchCV 탐색 공간은 C: [0.5, 1.0, 2.0], gamma: [scale, 0.05]로 설정하였으며, 탐색 결과 baseline과 동일한 파라미터가 최적으로 선택되어 두 run의 지표가 일치한다 (src/train.py tuning_grid() 함수).

모델명	계열	CV Bal.Acc	Test Bal.Acc	정밀도	재현율	F1
로지스틱 회귀 (기본)	로지스틱 회귀	0.8074	0.8301	0.8515	0.8431	0.8473
SVC (기본) ★	SVC	0.8272	0.8387	0.8476	0.8725	0.8599
랜덤 포레스트 (기본)	랜덤 포레스트	0.8027	0.8082	0.8091	0.8725	0.8396
SVC (튜닝)	SVC	0.8272	0.8387	0.8476	0.8725	0.8599

표 3. 모델별 CV 및 테스트 성능 비교

5. 최종 모델 선택

최종 모델로 SVC(기본)(MLflow run명: baseline_svc, model family: svc)를 선택하였다. 선택 기준은 test balanced accuracy가 최고 성능 대비 0.03 이내인 후보군 중에서 recall을 우선하고, 이후 F1과 balanced accuracy를 순차적으로 적용하는 방식이다 (src/train.py selection 로직, models/final_model_metadata.json). 표 3에서 보듯이 SVC(기본)은 재현율(0.8725)과 균형 정확도(0.8387) 모두에서 로지스틱 회귀·랜덤 포레스트 대비 우위를 보였다.

지표	값
균형 정확도 (Balanced Accuracy)	0.8387
정밀도 (Precision)	0.8476
재현율 (Recall)	0.8725
F1 점수	0.8599
CV 균형 정확도 (평균 ± 표준편차)	0.8272 ± 0.0426
선택된 특성 수	14개

표 4. 최종 선택 모델(SVC 기본) 성능 지표

임상 보조 맥락에서 recall 0.8725는 실제 심장병 환자 중 87.3%를 올바르게 감지한다는 의미이며, false negative를 최소화한다는 점에서 SVC(기본) 모델이 가장 적합하다. 정밀도(0.8476)와 F1(0.8599)도 후보군 중 최상위 수준으로, recall 우선 기준을 적용하면서도 전반적인 균형을 유지한다.




그림 2. 최종 모델 혼동 행렬 — 정상/심장병 분류 결과

6. 테스트, 패키징, CI

6.1 단위 테스트 (tests/test_pipeline.py)

tests/test_pipeline.py에 4개의 unittest 메서드를 작성하였다. 각 테스트의 의도는 다음과 같다:

테스트 메서드	검증 내용	중요한 이유
test_prediction_shape_matches_input_shape	predict() 출력 행 수 == 입력 데이터 행 수	배치 추론 시 누락/중복 예측을 조기에 탐지
test_predict_proba_range_and_row_sum	확률값 [0,1] 범위 내, 행별 합계 ≈ 1.0	확률 보정 오류나 파이프라인 변형 버그를 감지
test_clinical_range_validation_rejects_invalid_cholesterol	chol > 600 입력 시 ValueError 발생	임상적으로 불가능한 입력을 추론 전 차단 (src/preprocessing.py)
test_fixed_seed_pipeline_is_deterministic	동일 입력 두 번 실행 시 예측 결과 일치	random_state=42 고정으로 재현성 보장 검증

표 5. 파이프라인 단위 테스트 항목 및 검증 의도

6.2 Docker 패키징

Dockerfile은 python:3.10-slim 기반이며, requirements.txt로 의존성을 설치하고 코드와 저장된 모델을 이미지에 복사한다. slim 베이스 이미지를 사용하여 불필요한 시스템 패키지를 제외하고 이미지 크기를 최소화하였으며, API 키나 환경 변수 등 비밀값은 이미지에 포함하지 않았다. Docker 실행은 data/sample_input.csv의 8개 샘플에 대해 예측 CSV(artifacts/docker_predictions.csv)가 생성되는 방식으로 확인하였다.

```
docker build -t cardiocare:1.0 . && docker run --rm cardiocare:1.0
```

6.3 CI 워크플로 (.github/workflows/ci.yml)

GitHub Actions는 push 및 pull_request 이벤트마다 Python 3.10 환경에서 python -m unittest를 실행하도록 구성하였다. 이를 통해 저장소에 변경이 생길 때 기본 파이프라인 테스트가 자동으로 수행되도록 했다.

6.4 피쳐 스토어 및 모델 레지스트리

항목	대상	이유
----	----	----

피쳐 스토어 등록 대상	thalach (최대 심박수)	웨어러블·심전도 장비에서 실시간 갱신되는 특성으로, 최신값을 일관되게 제공하려면 중앙 피쳐 스토어에서 관리해야 함. 서빙 시 학습과 동일한 전처리 버전을 보장하는 데도 필수적임.
모델 레지스트리 기록 메타데이터	균형 정확도, 재현율, 선택 특성 목록, 학습 데이터 버전, 배포 일시	성능 기반 롤백 기준(균형 정확도·재현율) 제공; 선택 특성 목록은 서빙 입력 스키마 검증에 사용; 데이터 버전과 배포 일시는 감사 추적(audit trail)에 필수.

표 6. 피쳐 스토어 등록 대상 및 모델 레지스트리 메타데이터

7. 모니터링과 드리프트 탐지

7.1 추론 로깅 (src/inference.py)

src/inference.py는 Python 표준 logging 모듈을 사용하여 추론 시마다 타임스탬프, 모델 버전(cardiocare-1.0), 입력 shape, 예측값, 실제 정답(있는 경우)을 파일로 기록한다. 이 로그는 이후 모니터링 분석의 입력 데이터로 활용된다.

7.2 드리프트 시뮬레이션 및 KS 검정 (src/monitor.py)

드리프트 시뮬레이션 대상으로 chol과 oldpeak를 선택하였다. 두 특성은 SelectFromModel 기준 중요도 상위 특성이며, 콜레스테롤은 식이·약물 변화로, ST하강 수치는 검사 장비 보정이나 환자 컨디션에 따라 실제 임상 환경에서 단기간 내 분포가 이동할 수 있는 특성이기 때문이다. test set 복사본에서 chol의 분포를 평균 +30, 분산을 증가시키고 oldpeak도 인위적으로 이동시켰다. 각 연속형 특성에 대해 학습 데이터 분포 vs. 이동된 test 분포로 scipy.stats.ks_2samp를 실행하여 $p < 0.05$ 인 특성을 드리프트로 판정하였다.

드리프트 시뮬레이션은 실제 운영 환경의 완전한 재현은 아니지만, 입력 분포 이동이 balanced accuracy 하락으로 이어질 수 있음을 확인하기 위한 최소 시뮬레이션으로 설계하였다. test set 복사본에서 chol의 분포를 평균 +30, 분산을 증가시키고 oldpeak도 인위적으로 이동시켰다. 각 연속형 특성에 대해 학습 데이터 분포 vs. 이동된 test 분포로 scipy.stats.ks_2samp를 실행하여 $p < 0.05$ 인 특성을 드리프트로 판정하였다 (artifacts/drift_report.csv).

특성	KS 통계량	p-값	드리프트 여부
나이 (age)	0.0472	0.8793	정상
혈압 (trestbps)	0.0250	0.9999	정상
콜레스테롤 (chol)	0.3811	3.76e-19	감지됨
최대심박수 (thalach)	0.0581	0.7058	정상
ST하강 (oldpeak)	0.9078	4.78e-127	감지됨

표 7. KS 검정 결과 — 빨간 행이 드리프트 감지 특성

7.3 드리프트와 성능 저하

chol과 oldpeak의 분포 이동은 모델 성능에 직접적인 영향을 미쳤다. 원본 테스트셋의 균형 정확도 0.8387은 드리프트 테스트셋에서 0.6280으로 21.1%p 하락하였다 (artifacts/drift_performance_comparison.csv). 이는 입력 분포 이동이 성능 저하로 이어질 수 있음을 실험적으로 확인한 결과이다.

드리프트 전후 모델 성능 비교

데이터셋	Balanced Accuracy
원본 테스트셋	0.8387
드리프트 테스트셋	0.6280

성능 하락폭: 0.8387 → 0.6280 (Δ -0.2107)

그림 3. 드리프트 전후 Balanced Accuracy 비교 — 0.8387 → 0.6280




그림 4. 콜레스테롤 분포 이동 정도에 따른 성능 변화 시계열

8. 서빙과 재학습 전략

8.1 서빙 전략: Model-as-a-Service

현재 프로젝트의 규모와 맥락을 고려할 때 Model-as-a-Service(MaaS)가 적합하다. 세 가지 관점에서 정당화한다:

기준	MaaS 선택 근거
지연 시간	소규모 테이블형 모델의 서버 추론 지연은 수 밀리초 수준으로 관리 가능; 실시간 처리 요건에 부합
PHI/개인정보	서버 측에서 접근 제어, 전송 암호화, audit logging을 중앙 집중적으로 관리; On-Device 대비 보안 정책 적용 용이
업데이트 주기	모델 교체, 버전 롤백, 성능 모니터링을 서버에서 즉시 반영 가능; 클라이언트 업데이트 불필요

표 8. MaaS 선택 근거

8.2 재학습 전략과 Human-in-the-loop

drift flag 발생만으로 자동 재학습을 수행하지 않는다. 자동 재학습은 편향된 새 데이터로 모델을 교체할 위험이 있으며, 임상 환경에서는 그 결과가 직접 환자 안전에 영향을 미친다. 재학습 후보 승격 조건은 다음 세 가지를 모두

만족해야 한다:

조건	설명
① drift 지속성 확인	단일 시점의 통계적 이상이 아닌, 복수 관측 기간에 걸쳐 drift가 지속됨을 확인
② 성능 저하 확인	balanced accuracy 또는 recall이 사전 설정 임계값(예: 0.05p 이상 하락) 이하로 떨어짐
③ 사람 검토 후 label 확보	새 데이터에 대해 임상 전문가가 검토·승인한 label을 확보한 뒤 재학습 진행

표 9. 재학습 후보 승격 조건

Feedback loop 위험: 모델 예측이 전문의 권고 → 추가 검사 여부 → 새 label 생성에 영향을 주는 순환이 형성되면, 모델의 오류가 label 자체에 반영되어 재학습 시 더욱 강화되는 폭주 피드백 루프가 발생할 수 있다. 이를 방지하기 위해 모델 promotion 전 반드시 Human-in-the-loop review가 필요하며, 모델 예측과 독립적으로 획득된 ground truth label만 재학습에 사용해야 한다.

9. 한계, 윤리적 고려 사항, 추가 개선 방향

9.1 한계

CardioCare는 교육 목적의 프로토타입으로, 실제 의료 기기나 임상 의사결정 시스템으로 사용하기 위해서는 다음 사항들이 해결되어야 한다. 데이터는 1990년대 4개 기관에서 수집된 소규모 공개 데이터셋(918건)이며, 현재 임상 환경의 인구 분포 및 검사 방식을 충분히 반영하지 못한다. 단일 기관이나 특정 인구 집단에 맞춰 일반화되지 않았으므로 외부 검증 없이 실제 환경에 배포해서는 안 된다.

9.2 윤리적 고려 사항

실제 의료 적용 전 다음 작업이 필수적이다: (1) 외부 코호트를 활용한 독립 검증, (2) 예측 확률의 calibration curve 분석(모델이 0.7을 예측할 때 실제 70%의 환자가 심장병인지), (3) 성별·연령·민족 등 하위 그룹별 recall 분석(fairness audit), (4) PHI(Protected Health Information) 보호를 위한 암호화·접근 제어·익명화 설계. 또한 CardioCare는 어떠한 경우에도 심장 전문의의 판단을 대체하지 않으며, "알리되, 결정하지 않는" 보조 도구임을 시스템 UI와 문서에 명확히 표기해야 한다.

9.3 시간이 1주 더 있다면

항목	내용
Calibration curve	Platt scaling 또는 isotonic regression으로 확률 보정 후 신뢰 구간 기반 임상 의사결정 지원
Subgroup recall 분석	성별·연령대별 recall 비교로 fairness 취약 지점 파악
MLflow Model Registry	candidate → staging → production 승격 워크플로 구축; 모델 버전 및 메타데이터 중앙 관리
간단한 API serving	FastAPI + Pydantic으로 REST 엔드포인트 구성; 입력 유효성 검증 포함
현실적 drift simulation	실제 병원 운영 패턴(계절, 장비 변경)을 반영한 다변량 drift 시나리오 추가

표 10. 추가 개선 제안

10. AI 도구 사용 공개

본 프로젝트에서는 AI 도구를 코드 디버깅 보조, 보고서 구조화, 문장 다듬기 과정에 사용하였다. 다만 실험 실행, 산출물 확인, 최종 모델 선택과 해석은 repository의 코드와 결과 파일을 기준으로 직접 검토하였으며, 보고서의 수치와 결론은 실제 실행 결과에 근거한다.